

Sztuczna inteligencja i systemy ekspertowe

Zadanie 2: Poprawa lokalizacji UWB

1. Cel

Implementacja sztucznej sieci neuronowej w architekturze wielowarstwowego perceptronu (MLP) w celu poprawy dokładności odczytów lokalizacji robota w przestrzeniach zamkniętych, pozyskiwanych za pomocą technologii ultra-wideband (UWB). Analizie poddano wpływ parametrów konfiguracyjnych, struktury ukrytej oraz metod przeciwdziałających przeuczeniu na skuteczność modelu.

2. Wyniki

Program został zaimplementowany w języku **Python** w wersji 3.14.0 z wykorzystaniem biblioteki **PyTorch** (2.12.0) do stworzenia i uczenia sieci neuronowej oraz biblioteka **scikit-learn** (1.8.0) do normalizacji danych wejściowych.

2.1. Skalowanie danych

Wszystkie dane zostały przeskalowane z wykorzystaniem metody minmax zaimplementowanej w bibliotece scikit-learn (w wersji 1.8.0) do wartości z zakresu $[0,1]$. Metoda ta wykorzystuje następujący wzór:

$$X_{std} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (1)$$

$$X_{scaled} = X_{std} \cdot (max - min) + min \quad (2)$$


Gdzie min oraz max definiują zakres naszych wartości po przeskalowaniu (domyślnie od 0 do 1).

2.2. Parametry wybranych wariantów sieci


Sieć ma architekturę: 2 wejścia (zmierzone x, y) $\rightarrow$ warstwa ukryta $\rightarrow$ 2 wyjścia (skorygowane $\hat{x}, \hat{y}$); Dla każdej funkcji aktywacji wybrano wariant o najniższym MSE na zbiorze testowym.

	ReLU	Tanh	Logistic
Funkcja aktywacji	ReLU	Tangens hiperboliczny	Logistyczna
Liczba neuronów ukrytych	64	16	16
Inicjalizacja wag	Kaiming uniform (domyślne w PyTorch), $\mathcal{U}(-b, b)$, $b = \frac{1}{\sqrt{n_{\text{wej}}}}$		
warstwa wejściowa ($n_{\text{wej}} = 2$)	$\mathcal{U}(-0,707; 0,707)$		
warstwa wyjściowa	$\mathcal{U}(-0,125; 0,125)$	$\mathcal{U}(-0,250; 0,250)$	$\mathcal{U}(-0,250; 0,250)$
Optymalizator	Adam		
Współczynnik uczenia α	0,001	0,05	0,05
Współczynniki β_1, β_2	(domyślne w PyTorch dla Adam) $\beta_1 = 0,9$; $\beta_2 = 0,999$		
Maks. liczba epok	300		
Wczesne zatrzymywanie (cierpliwość)	20 epok bez poprawy MSE testowego		
Rozmiar mini-wsadu	128	64	64
Dropout	0,0 (wyłączony)		
Liczba niezależnych realizacji	5		


2.2.1. Kryterium 1: Wielkość błędu średniokwadratowego (MSE) w poszczególnych epokach uczenia na zbiorze treningowym danych statycznych



2.2.2. Kryterium 2: Wielkość błędu średniokwadratowego (MSE) w poszczególnych epokach w trakcie testowania sieci na danych dynamicznych



2.2.3. Kryterium 3: Dystrybuanty błędów wyznaczone dla skorygowanych wartości wszystkich wyników pomiarów dynamicznych



2.2.4. Kryterium 4: Zestawienie najlepszego wariantu sieci wraz z początkowymi pomiarami i trasą robota

